

AI技術を、人と社会へつなぐ 「AIエージェント」の設計思想

これまでの生成AIは、人の指示を待って答えるだけだった。いま、与えられた目標を達成するために、状況を把握し、自律的に判断し、実行するAIエージェントへと変容している。その頭脳の仕組み（ReACT）、記憶の仕組み（状態管理）、知識の調達（RAG）を分解し、医療・自治体・金融での実装例から、人と社会にどうつながるかを考える。

AIの「主語」が、人からAIへ移り始めている

生成AI技術は、人間の指示を待つだけの存在ではなくなった。与えられた目標を達成するために、状況を把握し、自律的に判断して実行する。この主語の転換が、AIエージェントという言葉の正体だ。

指示を待つ生成AI

聞かれたことに、一問一答で答える

1回のやり取りで、そこで完結する

次に何をするかは、そのつど人が決める

状況を把握し、自ら動くAIエージェント

目標だけを渡せば、手順は自分で組み立てる

状況を見ながら、必要な行動を続けて取る

観察した結果をもとに、次の一手を自分で選ぶ

定義 状況を把握し自律的に動くプログラム

生成AIが「頭脳」だとすれば、AIエージェントはその頭脳に、環境を認識する目と、実行する手足が備わった存在。目標だけを渡せば、状況判断から実行までを自律的にこなす。

転換点 「使う」から「任せる」へ


人が都度指示を出すのではなく、目標達成までの手順そのものをAIが設計し、実行していく。関係そのものが変わる。

この講義の地図 3つの仕組みと、社会実装を見る

ReACT（考えて動く頭脳）・状態管理（記憶の装置）・RAG（知識の調達）という3つの仕組みを分解し、最後に医療・自治体・金融の実装例を見る。

実装は「点・線・面・立体」の5段階で進む

単発のプロンプトから、完全自律型まで。レベル3と4のあいだで、段取りを決める主語が人からAIへ移る。



出典: おざけん資料アーカイブ「AIエージェント実装の5レベル」にもとづく。

見分け方 渡すものが「手順」か「目的」か

レベル1～3は**使うAI**。人が手順を渡す。レベル4～5は**任せるAI**。人が渡すのは目的だけになる。

断絶ではない ある日を境に切り替わるわけではない


レベル2で前提を渡し始めた時点で「任せる」は芽生えている。**移っていくのは、手順を決める重心。**

注意 レベル2と3は、どちらも「線」

2は前提を渡して答えさせる方向、3は手順を組んで走らせる方向。
3は2の発展形ではなく、別ルート。

エージェントの頭脳は、考えると動くを交互に回す

一つの技術の名前というより、いまのAIエージェントがほぼ例外なく内蔵している基本原理。最初の一手がうまくいなくても、観察した結果を踏まえてまた考え直せる。一発勝負で終わらないことが、この仕組みの値打ちだ。



出典: Yao et al. 「ReACT: Synergizing Reasoning and Acting in Language Models」 (2022年, arXiv:2210.03629)。

由来 Reasoning + Acting

2022年、「ReACT」という名前で提案された。「考える」だけでも「動く」だけでなく、この2つを1ステップずつ交互に繰り返すのが特徴。

何が変わるか 結果を見て、考え直せる

最初の判断が外れても、観察を踏まえて思考をやり直せる。軌道修正しながら目標に近づいていく。

大枠でとらえると 名前の注目度は下がり、原理は残った

ReACTという固有名詞が話題に上る頻度はいまや下がっている。だが理由は廃れたからではなく、大半のエージェント基盤に、名前を意識されないまま組み込まれ「当たり前」になったから。

状態管理は、「覚えている」を成り立たせる装置

考える・動く・確かめるのループを回し続けるには、それまでの経緯を覚えておく必要がある。一手ごとに記憶を失えば、エージェントはゴールに辿りつかない。

01 実行ログ

この一連の行動で、何をどう行ったか

02 作業中の一時変数

検索結果・計算の途中経過など、いまだけ使う値

03 長期記憶

これまでのやり取りや、好みの傾向を保存する

04 外部の記憶装置

ベクトルDB・ファイル・データベースに保存する

なぜ要るか 覚えていなければ、次の一手が選べない

思考・行動・観察を繰り返すには、それまでの経緯を踏まえる必要がある。これを支えるのが状態管理。

2つの記憶 短期はその場限り、長期は次回に持ち越す


実行中の一時的なメモと、セッションをまたいで残す記憶は、別の仕組みで管理されている。

限界 覚えられる量には、上限がある

コンテキストウィンドウという「机の広さ」を超えた分は、要約するか、**外部の記憶装置に逃がす**ほかない。

RAGは、答える前に外の知識を検索しにいく仕組み

Retrieval-Augmented Generation — 検索で拡張された生成。知識をモデルに覚え込ませるのではなく、答える直前に外部を検索し、見つかった断片だけを根拠にして答えさせる。学習ではなく、調達だ。



正体 覚えさせるのではなく、その場で調べて答える

答える前に外部知識を検索し、見つかった断片だけを根拠にして答えさせる仕組み。モデルの中に知識を蓄えるファインチューニングとは、**狙い**が違う。

エージェントでの役割 状況認識の材料を、外から取ってくる

エージェントが環境を認識するには、最新かつ固有の情報が要る。RAGは、その情報取得を担うスキルの一つとして働く。

利点 出典が示せて、差し替えがきく

参照する文書を更新すれば翌日から反映され、「どの文書に基づく回答か」を示せる。**学習させる手法にはない強み**だ。

データとコンテキストが、AIエージェントの土台になる

RAGが検索する「知識」も、エージェントが認識する「状況」も、元をたどれば組織のデータとコンテキストに行き着く。ここが薄ければ、上に積んだ仕組みは正しく機能しない。

01 運用・ガバナンス

更新のルールと、責任者を先に決めておく

02 AIツールの活用

システムプロンプトや制約を設計する

03 暗黙知の形式知化

業務マニュアルや議事録を、AIが読める形にする

04 動的コンテキスト

CRMやカレンダー、Slackなど最新のやり取り

05 データ基盤（器）

共有フォルダ・ナレッジベース・RAG用データの整備

出典: おざけん資料アーカイブ「コンテキスト&ハーネスエンジニアリング」にもとづく（簡略版）。

土台 「データ基盤（器）」が欠けると、上に何を積んでも崩れる

RAGが検索する断片も、エージェントが認識する状況も、すべてこの器から汲み上げている。

正本 「これが正しい」と決めた1つの版が要る


正本が複数ある組織では、AIは古い版を正確に読むだけになる。ハルシネーションに見える誤答の何割かは、実はここが原因。

詳しくは コンテキスト&ハーネスエンジニアリングへ

何を渡すか（コンテキスト）と、どう動かすか（ハーネス）の設計は、それ自体が独立した技術になっている。

AIエージェント時代、人の仕事の変え方

道具が変われば、育てるべきスキルも変わる。マニュアルになり、学習データになり、再現されるものから順に価値を失っていく。



AIとの関係	手順を覚え、道具を使いこなす	目的を渡し、Howを引き出す
価値の変化	希少だった鎧が、誰でも持てる前提になった	記述できないぶん、水面上に残り続ける
鍛え方	資格やツールの習熟を積み重ねる	課題を自分で見つけ、始める経験を積む

出典: おざけん資料アーカイブ「AIエージェント時代のキャリア」にもとづく。

何が沈むか

記述できる仕事から、順に代替されていく
難しさの順ではない。手順として書き出せるかどうか、順番を決めている。

残るもの

目的を持つ人から、順に代替されない
「始めること」だけは、AIに渡した瞬間に誰のものでもなくなる。
目的さえあれば、Howの大半はAIが埋めてくれる。

詳しくは

AIエージェント時代のキャリアへ
日本でも同じ順番の変化が数字に出はじめている。裸の戦いで何が残るかは、別の資料でさらに詳しく扱っている。

4つの部品が揃って、初めて「エージェント」になる

トリガー・Reason・状態管理・RAG。役割はそれぞれ違う。考えて動く頭脳だけがあっても、記憶と知識の調達が欠ければ、状況を把握し続けることはできない。

TRIGGER

トリガー

何が動かすか

メール受信・スケジュール・指示の3種類。ここから最初の思考が始まる。

REASON & ACT

頭脳

どう考え、動くか

考える・動く・確かめるのループで、繰り返す。

MEMORY

記憶

何を覚えておくか

状態管理が、実行ログと長期の記憶を支える。

KNOWLEDGE

知識

何を根拠にするか

RAGが、最新かつ固有の情報を検索して渡す。

骨格 4部品は役割が違う。どれか一つでは動かない

起点がなければ動き出さず、頭脳がなければ判断できず、記憶がなければ続かず、知識がなければ根拠を持ってない。

設計の要 環境認識の質が、エージェントの価値を決める

組織の暗黙知や業界の慣行をどれだけ「渡せる形」にできるかで、同じ4部品でも働きの質は変わる。

誤解しやすい点 賢いモデルを積み重ねる話ではない

モデルの性能ではなく、4部品をどう組み合わせで設計するかが、実装の分かれ目になる。

トリガーは3種類。人の仕事の起動条件と、同じ形をしている

レベルが「どこまで自律のか」を表す縦の軸なら、トリガーは「何をきっかけに動くか」という横の軸。AIの起動条件も、人の仕事とまったく同じ構造をしている。



出典: おざけん資料アーカイブ「AIエージェント実装の5レベル」にもとづく。

対応関係 人間の仕事と、同じ3つに分かれる

依頼を受けて動く、決まった時刻に動く、出来事に反応して動く。AIの起動条件も、人の仕事とまったく同じ構造をしている。

固定されない トリガーは、レベルに固定されない


どれが高度かではなく、レベルが上がるほど主役のトリガーが移り変わるのが要点。

注意 イベント型が、いちばん自律に近い

人も時計も待たずに動く。だからこそ、止め方と、越えてはいけない線を先に決めておく必要がある。

社会実装は、どこまで来ているか

医療・自治体・金融。それぞれの現場で、AIエージェントはすでに動きは始めている。派手な自動運転より先に、「照会に一次回答を用意し、人が確認して返す」という地味な現場から実装は進んでいる。



出典: おざけん資料アーカイブ「医療・自治体・金融のAI活用 完全ガイド」の活用事例にもとづく（2026年8月時点）。

共通点 どの例も「根拠を示す」形で使われている

自治体は例規の条文、金融は規程、医療は出典。RAGが支える「答えの裏付け」が、現場で使われる条件になっている。

役割で見え方が変わる 決める人・組む人・回す人

どこに置くかを決める人、閉域環境や監査証跡を設計する人、日々の照会や記録作成で実際に回す人。役割ごとに求められる理解が違う。

共通の失敗 出典を示せない設計は、現場で使われない

住民・顧客・患者に関わる場面ほど、「なぜその答えなのか」を示せないエージェントは定着しない。

「賢くなった」のではなく、「任せられる範囲が増えた」

AIエージェントという言葉には、誤解も多く積み重なっている。進化しているのは、モデルの知能そのものというより、状況を把握し、任せられる作業の範囲だ。

✕ 完全自律で、何でも人抜きに任せられる

権限とリスクに応じて、確認をどこに挟むかを線引きする設計がまだ必要になる

✕ 会話を続ければ、AIが勝手に賢くなる

実際は状態管理という設計があって初めて、その場の記憶が保たれているにすぎない

✕ RAGは、AIに知識を覚え込ませる技術だ

覚えさせるのではなく、答える前に外部を検索し、断片を根拠にする技術

○ ReACTは、結果を見てから考え直せる仕組みだ

一度の判断で終わらず、観察した結果を踏まえてまた考え直せる

落とし穴1 自律性は「全か無か」ではない

反応型から自律型まで、自律性には段階がある。業務のリスクに応じて、どこまで任せるかを設計する。

落とし穴2 出典のない回答は、現場では使われない

自治体・金融・医療、いずれも根拠を示せることが導入の条件だった。技術より先に、ここでつまづく。

これから 4つの部品を、業務にどう組むかが問われる

技術としての部品はすでに出そろっている。設計する側の理解が、次の分かれ目になる。

Summary

AIエージェントは、人の代わりではなく、 考え直せる相手になる

AI技術の主語がAIに移ったことは、人が要らなくなることを意味しない。ReACTが考え直す力を、状態管理が記憶を、RAGが最新の根拠を支える——この3つが揃って初めて、エージェントは安心して任せられる相手になる。

人と社会がAIエージェントとどう向き合うかは、技術の性能ではなく、この仕組みをどこまで理解し、どこに線を引くかで決まる。