

Claude Mythos全史 AIの臨界点を越えた日

Anthropicが「一般公開できない」と言い続けたモデルが、ついに公開された。
Mythos Previewから Fable 5リリースまでの全経緯と、日本への影響を読み解く。

OVERVIEW

Mythosクラスとは何か——Opusの「上」に生まれた新階層

2026年4月まで、Claudeのフラッグシップはモデルの序列上「Opus」が最上位だった。Mythosはその概念を刷新する。



モデル階層の刷新

MythosはOpusクラスの「上位階層」として定義された。単なる性能向上ではなく、モデルが実世界で引き起こせる影響の次元が変わった。



能力と危険の表裏一体

Mythosは設計目標にサイバーセキュリティを含めていないにも関わらず、主要OS・ブラウザすべての脆弱性を自力で発見・連鎖させる能力を発揮した。



一般公開まで2ヶ月の空白

4月のMythos Preview公開から6月9日のFable 5一般リリースまで、Anthropicは安全性検証に約2ヶ月を費やした。これは現代AIの公開判断史上でも異例の慎重さ。



OZAWA'S ONE POINT

小澤健祐 (おぞけん)

Mythosが示したのは「AIは強くなればなるほど危険になる」という当たり前の事実を、初めて企業が公式に認めて立ち止まったという**歴史的事件**だ。GPT-4発表以降、各社は競争優位のためにリリースを急ぐ傾向が強かった。Anthropicが「公開できない」と2ヶ月留保したのは、リスク管理の姿勢が本物であることの証明でもある。

TIMELINE

Mythos前後の全経緯——6つの転換点

2026年4月から6月9日のFable 5一般公開まで、約2ヶ月間で何が起きたか。

- 2026年 4月**
Claude Mythos Preview 発表 & Project Glasswing 始動
AnthropicはMythos Previewを発表。しかし一般公開はせず、AWS・Microsoft・Apple・Google・Cisco・JPMorganなどを含む限定パートナーのみにアクセスを提供。サイバー防衛を目的とした枠組み「Project Glasswing」を開始し、重要インフラプロバイダーが脆弱性を事前に修正できるよう先行利用を認めた。
- 2026年 4月～5月**
内部で「臨界能力」が次々と判明
Glasswingパートナーによるテストが進む中、Mythosが単独でゼロデイ脆弱性を連鎖発見できること、遺伝子療法設計の重要ステップをタンパク質言語モデルより高精度で実行できることが確認される。設計目標外での能力発現は、Anthropic内部でも想定を超えていた。
- 2026年 5月下旬～6月初旬**
Project Glasswingを15カ国・約150組織へ拡大
米国政府との協議のもと、Glasswingの対象を15カ国150以上の組織へと拡大。重要インフラ管理組織を中心に、Mythos Previewへの段階的アクセス提供が進む。この時点でMythosは「限定エリート向け」から「信頼組織ネットワーク」へとスケールし始めた。
- 2026年 6月8～9日 (前夜)**
「Code with Claude Tokyo」開催 & Fable 5チェックポイント発見
Anthropicが日本で3回目の開発者イベント「Code with Claude Tokyo」を開催。同日深夜、開発者コミュニティが内部テスト環境から「claude-fable-5」「Claude Fruitcake EAP」の2つの新チェックポイントを検出。X上で即座に拡散し、翌日の正式リリースが確信に変わった。
- 2026年 6月9日**
Claude Fable 5 + Claude Mythos 5 正式リリース
Fable 5として一般公開。Mythos 5としてGlasswingパートナー向け提供を同時発表。「Fable」はラテン語で「語られるもの (fabula)」, 「Mythos」はギリシャ語の「神話」。セーフガードの有無が2つを分かつ唯一の違いであり、命名に込められた意図は明快だ。価格は入力\$10/MTok・出力\$50/MTok (Mythos Preview比で半額以下) 。
- 2026年 6月23日～ (予定)**
サブスクリプションへの段階組み込み
6月22日までPro・Max・Team・Enterpriseに無料提供後、一旦クレジット制に移行。キャパシティが暫く収束、標準サブスクリプション機能として復辟予定。Anthropicは「なるべく早く戻す」と明言している。

MODEL COMPARISON

Fable 5 と Mythos 5——同じモデル、違うのはセーフガードだけ

混乱しやすいが、構造はシンプルだ。2つは「基盤モデルが同一」で「制約の範囲が異なる」だけ。

CLAUDE FABLE 5

一般向け・全世界公開

サイバー・生物学・化学・高層の4領域にセーフガード (クラシファイア) を実装。これらのタスクではOpus 4.8にフォールバック。セッションの95%以上はフォールバックなしでフル能力を利用できる。APIモデル名は **claude-fable-5**。



CLAUDE MYTHOS 5

信頼パートナー限定・Glasswingから順次

Fable 5と同じ基盤モデルだが、サイバーセキュリティ領域のセーフガードが解除されている。Glasswingパートナー (サイバー防衛) と近日常の生命科学研究者向けプログラムにのみ提供。価格は両者同一。

命名の語源: 「Fable (fabula)」, 「Mythos (mythos)」は同語族のラテン語とギリシャ語。どちらも「語り・物語」を意味し、制約で区別された2つのモデルが兄弟であることを示している。

CAPABILITIES

Fable 5が「別次元」と評される5つの理由

各社の早期テストで得られた具体的な証言と数値が、性能の飛躍を裏付けている。



Software Engineering

5,000万行のRubyコードを2ヶ月分1日に圧縮

Stripeは早期テストで「数ヶ月分のエンジニアリング作業が数日に圧縮された」と報告。具体的には5,000万行のRubyコードベース全体のマイグレーションを1日で完了 (人力では熟練チームで2ヶ月掛)。CognitionのFrontierCode評価では中程度のエフェートでもフロンティアモデル最高スコア。Cursorのベンチマークでも「以前は届かなかった長期タスクが可能になった」と評価。



Knowledge Work

ファイナンス・法律・分析で「シニアレベル」を初めて突破

HebbsのFinance Benchmark (シニアレベル評価) で全モデル中最高スコア。金融機関HCBは「取引分析評価ではほぼ全項目満点」と報告。法律AIのHarveyは「ブラインドレビューで弁護士が現行モデルと同等以上と判定した」と証言。Anaplanは「コアアナリティクスベンチマークで初めて90%超を達成、Opusより10ポイント向上」と明かした。



Vision

スクリーンショットだけでWebアプリを再構築・ポケモンを単独クリア

ビジョン単独でのタスク遂行能力が飛躍的に向上。スクリーンショットのみからWebアプリのソースコードを再構築できる。従来のClaudeモデルが補助ハーンズを使ってまで攻略できなかった「ポケモン ファイアレッド」を、Fable 5はビジョンのみの最小ハーンズでゲームクリアした。



Memory & Long-Context

数百万トークンで集中維持、自分のメモで自己改善

デッキ構築ゲーム「Slay the Spire」テストで、永続メモリを与えた場合の性能向上がOpus 4.8に3倍。最終幕到達率も3倍。長時間・長文タスクほどFable 5とその他モデルの差が開くという特性は、企業の複雑な業務フローとの相性が特に高い。



Life Sciences (Mythos 5限定)

創薬プロセスを10倍加速、138種の動物ゲノムを自律解析

Mythos 5を使った創薬テストでは、タンパク質設計プロセスの一部が約10倍加速。14標の中9標的で有望な候補化合物を特定済み。ゲノミクス研究では138種・数百万細胞のデータを1週間以上自律的に解析し、Science誌掲載モデルを100分の1のサイズで凌駕するMLモデルを開発した。

SAFETY ARCHITECTURE

なぜ公開できたのか——3種類のクラシファイアの仕組み

Fable 5を一般公開可能にしたのは、2ヶ月かけて構築した「検知・遮断」のレイヤー構造だ。



① サイバーセキュリティクラシファイア

攻撃的なサイバータスク全般を検知。外部バグ/ランタで1,000時間超のテストを実施し、ユニバーサルジェイルブレイクはゼロ。英国AISIが想定の変突破口を発見したものの、実用的な全面ジェイルブレイクは未達成。



② 生物学・化学クラシファイア

MythosはAAV (アデノ随伴ウイルス) の設計ステップを専用タスクバックキャストモデルより高精度でこなした。デュアルユース能力が確認されたため、生物学・化学関連タスクを広範にOpus 4.8へフォールバック。近日常に信頼研究者向けプログラムで解除予定。



③ 蒸留 (Distillation) クラシファイア

Claudeの能力を大規模抽出して融合モデルをトレーニングしようとする試みを検知。特に権威主義国家への技術流出リスクを念頭に置いた設計で、Fable 5に特有の新しいセーフガード層。

フォールバック先のClaude Opus 4.8は単体でも極めて高性能なモデル。「Fableがブロックされた＝何も応答しない」ではなく「Opusが代わりに答える」という設計は、ユーザー体験を損なわない配慮の結果。全セッションの95%以上でフォールバックは発生しない。

JAPAN UPDATE

日本でいま何が起きているか——Anthropicの「日本重視」が加速した背景

Fable 5発表と同日に東京でAnthropicの開発者イベントが開催されたのは偶然ではない。



「Code with Claude Tokyo」——Fable 5と同日、第3回を開催

2026年6月9日、AnthropicはFable 5のリリースと同じ日に東京で「Code with Claude Tokyo」を開催した (第3回)。前日の6月8日深夜には開発者コミュニティがFable 5のチェックポイントを発見しており、その文脈を踏まえると、東京イベントの設定はFable 5リリースと意図的に連動していた可能性が高い。日本の開発者コミュニティとのエンゲージメントを高めるタイミングとしても、戦略的に最適だった。



1 Glasswing 拡大 (5月下旬～6月初旬)

15カ国・約150組織への展開

Project GlasswingはMythos Previewの段階で当初の「数社」から「15カ国150以上の組織」へと拡大。重要インフラ管理組織が対象で、日本の重要インフラ関連企業が含まれる可能性がある。Anthropicは今後も「定期的な新規パートナー追加」を続ける予定と表明している。



2 API & Enterprise

Fable 5は本日より日本でも全面利用可能

Claude APIおよび従量課金制のEnterpriseプランから即日利用可能。モデル名は **claude-fable-5**、日本の企業にとっては、Opus 4.8を超える能力を持つモデルが即座に実業務へ組み込める状態になった。コーディング・知識業務・長期タスク全般で実用的な効果が期待できる。



3 Life Sciences (注目)

製薬・バイオ研究者向け信頼アクセスプログラムが始動へ

生物学・化学セーフガードを解除したFable 5 (実質的にMythos 5相当) へのアクセスを、少数の生命科学研究者に提供する信頼アクセスプログラムを開始。創薬10倍加速・ゲノミクス研究の自律実施という実績を持つMythosクラスの能力が日本の製薬企業・研究機関にも開放される可能性がある。



4 AI Policy Context

日本のAIガバナンスと「蒸留クラシファイア」の地政学

新設された「蒸留クラシファイア」は権威主義国家への技術流出防止を明示している。日本は民主主義国家として信頼性が高く、Glasswingの展開先・APIの自由利用においても相対的に優遇されうる立場にある。AI安全性への関心を強める経産省の動向とも方向が一致しており、日本の政府・企業が信頼アクセスプログラムに参加しやすい環境が整いつつある。



OZAWA'S ONE POINT

小澤健祐 (おぞけん)

Fable 5リリースと同日に「Code with Claude Tokyo」が開催されたのは、Anthropicが日本を**戦略的優先市場**と位置付けているサインだ。日本企業には今、Opus 4.8より一段上の能力を持つモデルを実業務に組み込むチャンスがある。AI/CX協会として、まずはコーディング・業務設計・長期タスクでのFable 5実装事例を積み上げることを推奨する。「まず試し、現場で磨く」が今の正解だ。

PRICING & AVAILABILITY

価格と提供スケジュール——知っておくべき3つの期間区分

需要が極めて高く予測困難なため、Anthropicは段階的な展開を選択した。スケジュールを正確に把握しておくことが重要。



\$10

入力トークン / 100万件



\$50

出力トークン / 100万件



1/2

Mythos Preview比 (半額以下)



Phase 1 — 本日～6月22日

Pro・Max・Team・Enterpriseに追加料金なしで提供

サブスクリプション加入者はこの期間中、Fable 5をフル利用できる。API・従量課金EnterpriseはPhase 1から関係なく即日利用可能。



Phase 2 — 6月23日～

サブスクリプションから一時除外、使用クレジット制へ

キャパシティ確保のため、サブスクリプションプランからFable 5を一旦切り離し、使用クレジットを購入すれば引き続き利用可能。Anthropicは「できるだけ早く標準機能として戻す」と明言。

Phase 3 — 時期未定

標準サブスクリプション機能として再提供

十分なキャパシティが確保できた時点で、Fable 5をサブスクリプションの標準モデルとして組み込む予定。変更は事前通知あり。

CONCLUSION

Mythosが変えたもの——AIの「責任ある公開」の新基準

Fable 5のリリースは単なる新モデル発表ではない。AIの能力水準と安全管理の両立をどこまで本気でやるかという、業界全体への問いかけだ。

能力の臨界点を越えた

Mythos登場まで、AIモデルは「賢い道具」だった。AIモデルはゼロデイ脆弱性の連鎖発見・タンパク質設計・ゲノミクス研究自律実施を実現し、「自律的な科学者」に近づいた。この質的変化は元に戻らない。

セーフガードのアーキテクチャが産業標準になる

クラシファイアとフォールバック・タスクバックキャストという3層構造は、今後の高性能モデル公開の雛形になる可能性が高い。日本のAIガバナンス議論にも参照モデルとして機能するだろう。

「信頼組織」という新しい格差

Glasswingパートナー (Mythos 5利用可) とその他 (Fable 5のみ) という階層構造が生まれた。どの組織が「信頼」を得られるかという問いは、AIリテラシーと安全管理体制の整備そのものだ。

「危険だから公開しない」でも「競争のために公開する」

でもなく——

「セーフガードが整ったから公開する」という判断。

これがAI開発の新しい標準になる。